

RustyClean 基准重跑状态

从零重跑全部建库与测试,取代 2026-08 的旧结果。**73 个任务全部完成**, 运行时间、内存与准确性均已测得。四个工具在"宿主残留"与"微生物误删"两条轴上排成一条清晰的取舍曲线, 这正是本项目要论证的不对称性。索引消融给出了与预期相反的答案。

集群 HPC2021 · amd 分区 项目目录 /lustre1/g/aos_shihuang/rustyclean-paper 作业总数 73 测量条数 136 + 16 准确性 更新 2026-09-04

73 任务全部完成	0.9992 RustyClean auto 中位 F1(最高)	3× 混合库的宿主残留更低	1 recheck 收益仍未测
--------------	-------------------------------------	------------------	--------------------

01 测试目的与设计

去宿主的两类错误代价并不对称。**漏掉的宿主序列会污染下游的丰度与功能分析**, 而**误删的微生物序列是永久的数据损失**,且在结果里看不出来——没有人会发现某个物种少了 1%。多数工具在这条轴上取一个固定位置,但真实样本的宿主比例从口腔拭子的 1% 到组织活检的 99% 不等。

RustyClean 的设计假设是:**按样本实际的宿主比例选择去宿主策略,能在两类错误之间取得比固定策略更好的平衡**。这次测试就是检验这个假设,并给出代价——时间、内存、以及在哪些场景下并无优势。

被测机制	做法	要验证什么
auto 路由	先抽 10 万条序列估计宿主比例:低比例走 bowtie2 比对,高比例走 kraken2 k-mer 分类	抽样估计是否准确;切换点是否落在该落的地方
recheck 验证通道	kraken2 判为宿主的序列,再用 bowtie2 复核一次才删	能挽回多少被误删的微生物序列,代价是多少时间

对照工具	它做什么	RUSTYCLEAN 的对应用法
KneadData	质控(trimmomatic + 串联重复屏蔽)+ 去宿主	auto ,带 fastp 质控
Hostile	只做去宿主,不做质控	auto --skip-qc

两组分开跑是为了让对比的范围一致。拿带质控的 RustyClean 去比只做去宿主的 Hostile, 等于让它多干一份活再比时间,得出的差距一部分是"多做的事"而不是"做得更快"。

衡量标准是**每条序列的真值标签**:数据由 InSilicoSeq 模拟,宿主序列来自 GRCh38、微生物序列来自 GTDB 群落, 因此每条序列的归属是已知的,可以逐条核对工具的判断。宿主序列从 GRCh38 模拟而去宿主对 T2T-CHM13v2.0 进行—— 两者是不同的组装版本,去宿主必须应对真实的组装差异,而不是匹配序列的来源本身。

为什么是"重跑"而不是首次测试

2026-08 的一轮结果已整体作废,归档于 `archive/v1/` 。主要原因有两条: **一是索引与 Methods 不符**——所有实验实际用的是 `kraken16` 混合库和 `hg_39` ,而非稿件描述的人类专用 T2T 索引;混合库下 Kraken2 会把宿主序列归到人类的祖先节点,很可能解释了当时观察到的大部分宿主残留。 **二是重复实验可能没有真正执行**—— 三次重复共用一个检查点目录,第 2、3 次可能直接返回而未做任何计算。 此外还有 Hostile 两个互相矛盾的运行时、正类约定不一致、以及 Methods 写的模拟器与代码实际调用的不是同一个。

这一轮的目标不只是拿到数字,更是让**每个数字都能追溯到它是怎么产生的**: 索引带来源标记、数据集带种子与实测序列长度、每次测量都记录在案。

02 阶段状态

六个阶段按依赖顺序提交。stage 3-6 通过 `afterok` 依赖 stage 1 与 stage 2, 因此上游任一任务失败,下游会被 SLURM 立刻取消——这是本轮多次"队列突然清空"的原因,不是下游自身出错。

Stage 1 — 参考索引构建 已完成 3 作业

索引	脚本	状态	备注
Kraken2 human-only (T2T)	<code>build_kraken2_t2t_only.sh</code>	已建成	4.3 GB,k=35 / l=31,33 个分类节点,已用 <code>kraken2-inspect</code> 验证
Bowtie2 T2T-only	<code>build_bowtie2_t2t_only.sh</code>	已重建	已去掉 <code>--large-index</code> ,现为 <code>.bt2</code> 小索引;T2T 单独 3.1 Gbp,不触及 Bowtie2 的 4 Gbp 上限
minimap2 / sylph / centrifuge	<code>build_aux_indexes.sh</code>	已建成	均带 provenance stamp,来源为同一份 T2T FASTA

Stage 2 — 模拟数据生成 已完成 18 任务 · 5.4 亿条序列

18 个数据集全部生成并通过校验:统一 `novaseq` 模型、151 bp、种子 43-60 各不相同、实际深度与声明值一致。 本阶段设有四道闸门——输入缺失报错、空数据集拒绝完成、深度偏差超 3% 报错、模型/种子不符自动重生成。

Stage 3 — 主对比实验

已完成

24 任务

时间与内存全部测得,四个后端齐全。centrifuge 曾因脚本手写的 PATH 不含它而 8 次全挂,修正后补跑完成。

实验	对比对象	结果	状态
RustyClean auto vs KneadData	KneadData(含 QC)	中位 4.42× 更快,最大 8.60×	8/8
RustyClean --skip-qc vs Hostile	Hostile(原始序列)	中位 0.99×,基本持平	8/8
后端运行时对比	bowtie2 / kraken2 / minimap2 / centrifuge	kraken2 4分37秒 · centrifuge 7分50秒 · bowtie2 18分09秒 · minimap2 31分01秒	32/32

Stage 4 — 验证通道与索引消融

已完成

15 任务 · 各 3 次重复

三条臂的时间与内存都已测得,消融的准确性也已得出并给出了与预期相反的答案(见 03 节)。
唯一缺口是无 recheck 基线臂没有准确性——它的评分作业存在但从未被 stage 6 提交,已补进流水线。

实验	中位运行时间	峰值内存	状态
Kraken2 基线(无 recheck)	15 分 33 秒	12.3 GB	缺准确性
Kraken2 + Bowtie2 recheck	24 分 18 秒	12.7 GB	已测
索引消融(混合库)	13 分 56 秒	15.6 GB	已测

Stage 5 — 此前未测量的部分

已完成

9 任务

此前一轮用错了参考索引(指向 Hostile 的 T2T+HLA),结果已作废;本轮脚本已改为使用本项目的纯 T2T 索引, 重跑完成。决策边界扫描给出 bowtie2 与 kraken2 在各宿主比例下的实测代价。

实验	结果	峰值内存	状态
auto 路由决策边界	bowtie2 中位 3 分 40 秒 • kraken2 中位 2 分 11 秒	3.1 / 4.8 GB	6/6
双端 panel	RustyClean 15 分 23 秒 • Hostile 17 分 46 秒 • KneadData 45 分 26 秒	3.6 GB	3/3

Stage 6 — 准确性与资源汇总

已完成


4 作业

四工具对比、索引消融、recheck 臂的准确性全部产出真实数值,资源汇总 136 条测量。
recheck 臂曾两次给出全零结果:第一次是真值 ID 带着描述和 /1 后缀对不上, 第二次是包装脚本不 source config.sh、回退到了本项目早已弃用的旧 scratch, 拿新结果去对旧标签打分。两处都已修,并加了零匹配守卫。

03 已得到的结果

运行时间与内存峰值来自 /usr/bin/time -v ,每次工具调用一条记录,合计 136 条, 汇总于 runs/summary/resources.csv 。准确性数字尚不可用,原因见第 06 节。

对 KneadData:优势随宿主比例与深度增长



◆ 相对 KneadData 的加速比 ▲ 相对 Hostile 的加速比

对 KneadData 的优势随宿主比例单调上升,从持平到 8.6 倍;对 Hostile 始终贴着 1× 那条线。

90% 处的两个点(5.78× 与 6.60×)来自 30M 和 60M 两个数据集,说明深度也有贡献。

数据集	RUSTYCLEAN AUTO	KNEADDATA	倍数
5M_1pct_low_even_SE	3.3 分	3.2 分	0.99×
5M_5pct_low_even_SE	3.2 分	3.4 分	1.09×
10M_10pct_med_even_SE	4.8 分	8.2 分	1.72×
30M_50pct_high_skewed_SE	9.1 分	40.3 分	4.42×
30M_70pct_med_lognormal_SE	11.7 分	38.1 分	3.27×
30M_90pct_med_lognormal_SE	9.4 分	54.5 分	5.78×
60M_90pct_high_lognormal_SE	17.4 分	114.9 分	6.60×
60M_99pct_med_lognormal_SE	15.9 分	136.9 分	8.60×


在 5M / 1% 宿主上两者**没有差别**(0.99×),优势从 10M / 10% 开始出现,到 60M / 99% 达到 8.60×。 这条趋势本身就是论证:auto 路由在宿主占比高时才切换到 kraken2,加速正出现在它该出现的地方。

对 Hostile:速度基本持平

数据集	RUSTYCLEAN --SKIP-QC	HOSTILE	倍数
5M_1pct_low_even_SE	3.6 分	1.9 分	0.54×
5M_5pct_low_even_SE	3.4 分	2.3 分	0.68×
10M_10pct_med_even_SE	3.5 分	3.2 分	0.91×
30M_50pct_high_skewed_SE	6.5 分	8.6 分	1.32×
30M_70pct_med_lognormal_SE	8.0 分	9.1 分	1.14×
30M_90pct_med_lognormal_SE	9.5 分	5.9 分	0.62×
60M_90pct_high_lognormal_SE	14.6 分	14.5 分	0.99×
60M_99pct_med_lognormal_SE	14.2 分	15.4 分	1.08×

中位 0.99×,且在小数据集上 RustyClean **更慢**(最低 0.54×)。对 Hostile 不存在速度优势,论文里若要主张,只能主张持平——这也让准确性成为唯一能区分二者的维度。

内存:RustyClean 的代价



工具 / 后端	峰值内存	样本数	说明
RustyClean k2 混合库	15.6 GB	15	仅消融实验使用
minimap2 后端	13.4 GB	8	后端中最耗内存也最慢
RustyClean + recheck	12.7 GB	15	相对基线仅增 0.4 GB
RustyClean k2 基线	12.3 GB	15	常驻 Kraken2 哈希表
RustyClean auto	6.7 GB	8	主对比实验
Hostile	3.5 GB	8	
KneadData	1.1 GB	11	内存占用最低

RustyClean 用时间换内存:比 KneadData 快最多 8.6 倍,但峰值内存是它的 6–14 倍。
这是 Kraken2 哈希表常驻的直接后果,应当如实报告,而不是只讲速度。


recheck 验证通道的开销

数据集	基线	+ RECHECK	增幅
30M_50pct_high_skewed_SE	9.4 分	14.0 分	+48.9%
60M_90pct_high_lognormal_SE	14.7 分	16.7 分	+13.4%
60M_99pct_med_lognormal_SE	13.4 分	22.4 分	+66.8%
100M_50pct_high_lognormal_SE	22.8 分	36.2 分	+58.6%
100M_90pct_high_lognormal_SE	20.9 分	27.4 分	+31.1%

时间增加 13%–67%,内存几乎不变(12.3 → 12.7 GB)。 这个代价值不值,取决于它挽回多少假阳性——而那正是目前缺失的准确性数字。

准确性:两类错误的取舍曲线

正类为"微生物序列被保留"。**横轴是没能清除的宿主序列(污染残留), 纵轴是被误删的微生物序列(数据损失)**。越靠近左下角越好,而没有工具能同时到达两端—— 四个工具连成的这条线就是取舍本身。每个工具四个点,对应四个数据集;细线按测序深度串联。



● RustyClean auto ■ RustyClean --skip-qc ▲ Hostile ◆ KneadData

Hostile 停在左上角外侧:一条微生物序列都不丢,但宿主残留 2~2.7%。**KneadData 在右下角:**宿主清得最干净,却误删了近 1% 的微生物序列。**RustyClean auto 落在拐点**——两个方向都接近

最优,F1 因此最高。悬停任一标记可看具体数值。

正类为"微生物序列被保留"。**FP 是没能清除的宿主序列**(污染残留), **FN 是被误删的微生物序列**(数据损失)。两者不可同时最小化,四个工具正好排成一条单调的取舍曲线。

数据集	工具	宿主残留 FP	微生物误删 FN	F1
5M_1pct_low_even_SE	Hostile	1,023 • 2.05%	0 • 0.000%	0.9999
	RustyClean --skip-qc	859 • 1.72%	123 • 0.002%	0.9999
	RustyClean auto	209 • 0.42%	7,712 • 0.156%	0.9992
	KneadData	149 • 0.30%	43,739 • 0.884%	0.9955
10M_10pct_med_even_SE	Hostile	26,252 • 2.63%	0 • 0.000%	0.9985
	RustyClean --skip-qc	23,326 • 2.33%	596 • 0.007%	0.9987
	RustyClean auto	4,151 • 0.42%	5,269 • 0.059%	0.9995
	KneadData	3,077 • 0.31%	61,114 • 0.679%	0.9964
30M_50pct_high_skewed_SE	Hostile	399,819 • 2.67%	0 • 0.000%	0.9868
	RustyClean --skip-qc	310,060 • 2.07%	1,244 • 0.008%	0.9897
	RustyClean auto	39,892 • 0.27%	13,481 • 0.090%	0.9982
	KneadData	30,897 • 0.21%	95,774 • 0.638%	0.9958
60M_90pct_high_lognormal_SE	Hostile	1,057,928 • 1.96%	0 • 0.000%	0.9190
	RustyClean --skip-qc	889,123 • 1.65%	687 • 0.011%	0.9310
	RustyClean auto	135,380 • 0.25%	5,531 • 0.092%	0.9884
	KneadData	111,645 • 0.21%	58,174 • 0.970%	0.9859

四个数据集的中位数	宿主残留	微生物误删	F1	
Hostile		2.63%	0.000%	0.9985
RustyClean --skip-qc		2.07%	0.008%	0.9987
RustyClean auto		0.42%	0.092%	0.9992
KneadData		0.30%	0.884%	0.9958

三点值得写进论文:**RustyClean auto 的 F1 最高**(0.9992); KneadData 的宿主清除最彻底(0.30%),代价是误删的微生物序列比 RustyClean auto **多近十倍**(0.884% vs 0.092%), F1 因此垫底;**RustyClean --skip-qc 在两条轴上都优于 Hostile**——宿主残留低 0.56 个百分点,而多付出的微生物损失只有 0.008%。在 60M / 90% 宿主这个极端点上,Hostile 残留 105 万条宿主序列, RustyClean auto 只有 13.5 万条。

索引消融:结果与预期相反

v1 的推断是:混合库(`kraken16`)下 Kraken2 会把宿主序列归到人类的祖先节点,从而逃过按 taxid 的宿主判定,**因而应当有更高的宿主残留**。实测把这个推断推翻了。

数据集	宿主残留 混合库	人类专用库	微生物误删 混合库	人类专用库
30M_50pct_high_skewed_SE	0.079%	0.249%	0.084%	0.091%
60M_90pct_high_lognormal_SE	0.101%	0.238%	0.084%	0.094%
100M_50pct_high_lognormal_SE	0.054%	0.216%	0.085%	0.095%
100M_90pct_high_lognormal_SE	0.089%	0.279%	0.085%	0.096%
平均	0.081%	0.245%	0.084%	0.094%

混合库在两条轴上都更好:宿主残留低约 3 倍(0.081% vs 0.245%),微生物误删也略低,F1 为 0.99729 对 0.99320。一个合理的解释是:人类专用库里,任何与人类共享少量 k-mer 的序列 **都没有别的归属可选**;混合库给了 Kraken2 微生物的参照,反而判得更准。v1 担心的"LCA 逃逸"没有出现——至少在开启 recheck 的情况下没有。

这个结果**不支持**为祖先 taxid 补丁而合并 `feat/host-taxid-lineage` 分支: 它要解决的问题在实测中并不存在。但要注意两臂都开启了 recheck,验证通道可能掩盖了差异——在下一条说明的对照补齐之前,这个结论仅在"开启 recheck"的前提下成立。

auto 路由:估计准确,切换点符合设计

数据集	标称宿主比例	抽样估计	选择的后端
5M_1pct_low_even_SE		1%	0.98% bowtie2
5M_5pct_low_even_SE		5%	4.98% bowtie2
10M_10pct_med_even_SE		10%	9.87% bowtie2
30M_50pct_high_skewed_SE		50%	49.41% kraken2
30M_70pct_med_lognormal_SE		70%	69.23% kraken2
30M_90pct_med_lognormal_SE		90%	89.16% kraken2
60M_90pct_high_lognormal_SE		90%	89.68% kraken2
60M_99pct_med_lognormal_SE		99%	98.63% kraken2

十万条序列的抽样估计与标称值最大偏差 0.59 个百分点,八个数据集全部正确路由: $\leq 9.87\%$ 走 bowtie2, $\geq 49.41\%$ 走 kraken2。这条规则的两半——估计准确、切换合理——都得到了验证。

04 软件

被测工具是 RustyClean;KneadData 与 Hostile 是对照工具,均使用各自官方发布的默认数据库,不做修改。 其余为 RustyClean 各后端所依赖的比对/分类程序。

软件	角色	用于	位置
RustyClean	被测工具	stage 3-5 全部实验	rustyclean/target/release
KneadData	对照工具	stage 3 主对比	conda envs/kneaddata
Hostile	对照工具	stage 3 --skip-qc 对比	~/.local/bin
InSilicoSeq	序列模拟	stage 2 生成全部数据	.conda_envs/rustyclean-benchmark
Kraken2	RustyClean 后端	k-mer 分类去宿主	conda envs/kraken2
Bowtie2	RustyClean 后端	比对去宿主 + recheck 验证通道	conda envs/metaphlan
minimap2	RustyClean 后端	后端对比	.conda_envs/rustyclean-benchmark
sylph	RustyClean 后端	sketch 预筛	conda envs/sylph
centrifuge	RustyClean 后端	后端对比	.conda_envs/rustyclean-benchmark
fastp	质控	RustyClean 默认 QC 步骤	conda envs/metagem
samtools / seqtk	辅助	比对输出处理 / auto 模式抽样	conda envs

05 参考序列与数据库

核心设计:宿主序列从 GRCh38 模拟,去宿主对 T2T 进行。两者是不同的组装版本,因此去宿主必须应对真实的组装差异,而不是匹配序列的来源本身。本项目构建的五个索引全部来自同一份 T2T FASTA,并带 provenance stamp 记录来源。

类别	名称	用途	状态
参考序列	T2T-CHM13v2.0 GCF_009914755.1	去宿主参考,五个索引的共同来源	就绪
参考序列	GRCh38.p14 GCF_000001405.40	宿主序列的模拟来源	就绪
参考序列	GTDB r202 参考基因组	微生物群落取材,9,057 个基因组	就绪
分类信息	NCBI taxonomy	Kraken2 与 centrifuge 建库	就绪
本项目索引	Kraken2 human-only (T2T)	默认后端,除消融外全部实验使用	已建成
本项目索引	Bowtie2 T2T-only	比对后端与 recheck 验证通道	已重建 (.bt2)
本项目索引	minimap2 / sylph / centrifuge (T2T)	后端对比	已建成
消融对照	Kraken2 mixed kraken16	仅索引消融实验;含人类以外多个类群	就绪
对照工具库	KneadData hg39_T2T	KneadData 官方默认库	就绪
对照工具库	Hostile human-t2t-hla	Hostile 官方默认库(T2T + IPD-IMGT/HLA)	就绪

一处必须在论文中说明的不对称

Hostile 的默认索引在 T2T 之外还包含 IPD-IMGT/HLA,而本系统上没有 HLA 序列,因此 RustyClean 的所有索引都是纯 T2T。这个差异是比较本身的属性,应当如实报告,而不是通过改动 Hostile 的默认配置来抹平。

06 模拟数据集

18 个数据集,合计 5.4 亿条序列,覆盖测序深度(5M–100M)、宿主比例(0–100%)、群落复杂度(5/30/100 物种)、丰度分布(均匀/对数正态/偏斜)与测序模式(单端/双端)。群

落按复杂度用固定种子随机抽样, 同一复杂度的数据集共用同一群落,因此跨深度与跨宿主比例可比。

数据集	序列数	宿主	复杂度	丰度分布	模式	种子
5M_1pct_low_even_SE	5,000,000	1%	low · 5 种	even	SE	43
5M_5pct_low_even_SE	5,000,000	5%	low · 5 种	even	SE	44
10M_0pct_med_lognormal_SE	10,000,000	0%	med · 30 种	lognormal	SE	59
10M_1pct_med_lognormal_SE	10,000,000	1%	med · 30 种	lognormal	SE	45
10M_5pct_med_lognormal_SE	10,000,000	5%	med · 30 种	lognormal	SE	46
10M_10pct_med_even_SE	10,000,000	10%	med · 30 种	even	SE	47
10M_30pct_med_lognormal_SE	10,000,000	30%	med · 30 种	lognormal	SE	48
10M_100pct_med_lognormal_SE	10,000,000	100%	med · 30 种	lognormal	SE	60
20M_10pct_med_even_PE	20,000,000	10%	med · 30 种	even	PE	57
20M_50pct_med_lognormal_PE	20,000,000	50%	med · 30 种	lognormal	PE	49
20M_90pct_med_lognormal_PE	20,000,000	90%	med · 30 种	lognormal	PE	58
30M_50pct_high_skewed_SE	30,000,000	50%	high · 100 种	skewed	SE	50
30M_70pct_med_lognormal_SE	30,000,000	70%	med · 30 种	lognormal	SE	51
30M_90pct_med_lognormal_SE	30,000,000	90%	med · 30 种	lognormal	SE	52
60M_90pct_high_lognormal_SE	60,000,000	90%	high · 100 种	lognormal	SE	53
60M_99pct_med_lognormal_SE	60,000,000	99%	med · 30 种	lognormal	SE	54
100M_50pct_high_lognormal_SE	100,000,000	50%	high · 100 种	lognormal	SE	55
100M_90pct_high_lognormal_SE	100,000,000	90%	high · 100 种	lognormal	SE	56

模拟器为 InSilicoSeq, `novaseq` 误差模型, 实测序列长度 151 bp。每个数据集写入 `metadata.json` 记录实测序列长度、模型与种子; 序列长度是从产出的序列中量取的, 而非写死的常数, 因此 Methods 可以对照数据核实。

07 待决事项

recheck 的收益仍未测量 — 唯一实质缺口

验证通道的代价已知: 多花 13% 到 67% 的运行时间, 内存几乎不变。但它换回多少被误删的微生物序列, **至今没有数字**——无 recheck 基线臂的评分作业 (`run_accuracy_baseline_k2.sh`) 一直存在, 却从未被 stage 6 提交, 所以那一臂只有运行时间和内存。已补进流水线, 重跑 stage 6 即可得到。

这也影响上一条结论的边界: 索引消融的两臂都开启了 recheck, 在拿到无 recheck 的对照之前, "混合库更好" 仅在开启验证通道的前提下成立。

论述重心应从速度移到准确性

对 Hostile 的速度是持平 (中位 0.99 $\times$), 但准确性上 RustyClean `--skip-qc` 在两条轴上都更优。对 KneadData 则相反: 速度快 4.4–8.6 倍, 而 KneadData 的宿主清除 略胜一筹 (0.30% vs 0.42%), 代价是误删近十倍的微生物序列。论文的主张应当是 "在两类错误之间取得更好的平衡", 而不是单纯的速度。

内存是需要如实交代的代价

RustyClean 的 kraken2 路径峰值 6.7–15.6 GB,而 KneadData 只要 1.1 GB、Hostile 3.5 GB。这是 Kraken2 哈希表常驻的直接后果。速度与准确性的优势建立在更高的内存占用之上,对内存受限的使用者,这个取舍应当写明。

三次重复只测量了时间波动

消融与 recheck 的 rep1/rep2/rep3 每个准确性数字都一模一样。这符合预期——确定性工具、同样输入、输出必然相同——但意味着这三次重复在准确性上没有提供任何额外信息,论文中不应把它们当作独立重复。

本轮暴露的两类数据缺陷,均已加守卫

静默的全零结果。准确性脚本在一条都匹配不上时会输出一整张 precision 0、recall 0 的表,与"工具删掉了一切"无法区分。现在命中数为零会直接报错。

静默的重复累积。三个 benchmark 脚本只在文件不存在时写表头,重跑会追加而非覆盖,失败的那次与重跑结果被一起算了平均。现在每次运行覆盖,汇总也会按时间戳剔除被取代的测量并报数——本次剔除了 32 条。